GESTIÓN DE COSTOS OPERATIVOS

Modelo: Error Correction Model (ECM) con validación out-of-sample

Datos históricos: Ene 2010 – Ago 2023 | Proyección: Sep 2023 – Ago 2024

Nicolás Tibatá | Abril 2026

1. Explicación del Caso

Una empresa del sector de la construcción se encuentra en la fase de planificación de un proyecto con una ventana de ejecución definida. Durante este período debe gestionar el suministro continuo de dos tipos de equipos críticos para las operaciones en campo.

El desafío central radica en que el costo de adquisición de dichos equipos ha mostrado históricamente un comportamiento variable que la empresa no ha logrado anticipar, generando desviaciones presupuestales recurrentes.

La gerencia sospechaba que los precios de los equipos guardan alguna relación con ciertos insumos del mercado de materias primas, pero no contaba con un modelo formal que respaldara esta hipótesis ni con claridad sobre qué insumos son determinantes para cada equipo.

Objetivo del análisis

Desarrollar un modelo estadístico reproducible que permita:

- Identificar cuáles materias primas explican el comportamiento del precio de cada equipo.
- Proyectar el costo esperado de los equipos con intervalos de confianza para los próximos meses.
- Reducir las desviaciones presupuestarias asociadas a la volatilidad en los precios de insumos.
- Establecer una base analítica para evaluar y comparar proveedores de forma objetiva.

Datos disponibles

Archivo	Contenido	Período	Frecuencia
historico_equipos.csv	Precio diario de X, Y, Z, Equipo 1 y Equipo 2	Ene 2010 – Ago 2023	Diaria
X.csv	Serie de precios de materia prima X	Abr 2024 (extensión)	Diaria
Y.csv	Serie de precios de materia prima Y	Sep 2023 (extensión)	Diaria
Z.csv	Serie de precios de materia prima Z	Ene 2010 –	Diaria

Al tener datos cómo extensión pero sin su relación con los equipos 1 y 2 deciden no usarse dentro del modelado, ya que generaría ruido al modelo ECM.

El archivo principal historico_equipos.csv contiene 3.530 registros diarios sin valores nulos, lo que representa una base de datos muy buena para el análisis.

2. Supuestos

Supuestos del análisis

- Las relaciones entre las materias primas y los equipos son estables en el tiempo (no hay quiebres estructurales significativos en el período analizado).
- El precio de los equipos en t es función del precio de la materia prima en t (relación contemporánea) más la corrección del desequilibrio acumulado.
- Se trabaja con datos mensuales para la proyección (resampleo de la serie diaria) dado que la planificación financiera opera en esa escala.
- La incertidumbre de la proyección se propaga a través de los residuales del modelo (bootstrap), capturando tanto el error del ECM como la variabilidad de la materia prima.

Supuestos metodológicos

- La evaluación del modelo se realiza con split temporal (80% train / 20% test, sin shuffle) para respetar la dependencia temporal de las series y poder generar su pronóstico.
- Los intervalos de confianza se construyen con 1.000 simulaciones bootstrap de los residuales del ECM, usando percentiles 2.5/10/90/97.5.
- Price_X se descarta si no presenta cointegración con ningún equipo; Price_Y y Price_Z se retienen sólo si son estadísticamente significativas en el modelo de corrección de errores.

3. Formas de Resolver el Caso

Enfoques considerados

Para estimar la relación entre materias primas y costos de equipos se evaluaron tres familias de enfoques:

Enfoque	Descripción	Ventaja	Limitación
OLS en niveles	Regresión lineal directa entre precios de equipos y materias primas.	Simple e interpretable.	Inválido si las series no son estacionarias (regresión espuria).
Modelos en diferencias	Modelar cambios diarios en lugar de niveles absolutos.	Elimina el problema de no estacionariedad.	Pierde la relación de largo plazo; acumulación de errores en proyección.
Error Correction Model (ECM)	Combina dinámica de corto plazo y corrección al equilibrio de largo plazo.	Estadísticamente correcto para series cointegradas; captura ambas dinámicas.	Mayor complejidad técnica; requiere test de cointegración previo.

Enfoque seleccionado: ECM con cointegración de Engle-Granger

La decisión de usar el ECM se fundamenta en el diagnóstico estadístico de los datos:

- El test ADF confirmó que la mayoría de las series son no estacionarias (Price_X, Price_Y, Price_Equipo1: $p > 0.05$).
- El test de cointegración de Engle-Granger reveló relaciones de largo plazo válidas entre Y-Equipo1 ($p=0.013$) y Z-Equipo2 ($p=0.008$).
- La correlación en niveles era artificialmente alta ($r=0.99$ para Y-Equipo1) pero caía dramáticamente en diferencias ($r=0.39$), evidenciando que el OLS simple habría sido espurio.
- Price_X fue descartada al no mostrar cointegración con ningún equipo ($p=0.50$ y $p=0.57$).

ECM $\Delta y_t = \alpha + \beta \cdot \Delta x_t + \gamma \cdot (y_{t-1} - \lambda \cdot x_{t-1}) + \varepsilon_t$ donde β = efecto de corto plazo y γ = velocidad de corrección al equilibrio (< 0)

El flujo metodológico completo fue:

- Fase 1: EDA — exploración de series, estadísticos descriptivos, detección de outliers.
- Fase 2: Correlación con rezagos (lag 0–6 meses) + test ADF de estacionariedad + VIF de multicolinealidad + test de cointegración.
- Fase 3: Estimación del ECM con split temporal 80/20; evaluación con MAE, RMSE, MAPE y R^2 out-of-sample.
- Fase 4: Proyección de materias primas (Holt-Winters) + propagación al ECM + bootstrap de IC.

4. Resultados del Análisis de Datos y Modelos

Análisis exploratorio

Las series de precios diarios cubren el período enero 2010 a agosto 2023 (3.530 observaciones). No se detectaron valores nulos. El análisis de estacionariedad con el test ADF arrojó los siguientes resultados:

Variable	ADF Estadístico	p-valor	Estacionaria
Price_X	-1.754	0.4036	No
Price_Y	-1.962	0.3036	No
Price_Z	-2.923	0.0428	Sí
Price_Equipo1	-1.938	0.3143	No
Price_Equipo2	-3.067	0.0291	Sí

Diagnóstico de relaciones

La correlación de Pearson en niveles mostraba valores muy altos (r = 0.99 para Y-Equipo1), pero al analizar en diferencias la correlación disminuyó, revelando que las relaciones en niveles eran espurias:

Materia Prima	r con Equipo 1 (niveles)	r con Equipo 1 (diferencias)	r con Equipo 2 (niveles)	r con Equipo 2 (diferencias)
Price_X	0.523	0.048	0.530	0.085
Price_Y	0.997	0.386	0.913	0.128
Price_Z	0.844	0.024	0.983	0.431

El test de cointegración de Engle-Granger identificó las relaciones estadísticamente válidas de largo plazo:

Par	p-valor	Decisión
Price_X → Equipo 1	0.4996	No cointegradas — descartada
Price_X → Equipo 2	0.5747	No cointegradas — descartada
Price_Y → Equipo 1	0.0130	Cointegradas — incluida
Price_Y → Equipo 2	0.0026	Cointegradas — evaluada
Price_Z → Equipo 1	0.0059	Cointegradas — evaluada
Price_Z → Equipo 2	0.0084	Cointegradas — incluida

Selección final de variables

El modelo multivariado Equipo1 ~ Y + Z mostró que Price_Z es completamente irrelevante cuando Price_Y ya está incluida ($p = 0.672$, coeficiente = -0.002). Por tanto los modelos definitivos son:

Equipo	Driver seleccionado	Variables descartadas	Justificación
Equipo 1	Price_Y	Price_X (sin cointegración), Price_Z (p=0.672 con Y presente)	Y tiene R^2 largo plazo = 0.9932
Equipo 2	Price_Z	Price_X (sin cointegración), Price_Y (redundante)	Z tiene R^2 largo plazo = 0.9656

Resultados del ECM

Los coeficientes del ECM para cada modelo:

Parámetro	Equipo 1 ~ Y	Equipo 2 ~ Z
R^2 largo plazo	0.9932	0.9656
R^2 ECM (corto plazo)	0.4770	0.2904
β (efecto contemporáneo)	0.750 ***	0.353 ***
γ (velocidad corrección)	-0.771 ***	-0.256 ***
Velocidad de ajuste	77% por período	26% por período

El coeficiente γ de Equipo 1 (-0.77) indica que ante cualquier desequilibrio, el precio del equipo corrige el 77% de esa brecha en el siguiente período. Para Equipo 2, la corrección es más gradual (26%).

Desempeño out-of-sample (test set: 20% final)

Métrica	Equipo 1 ~ Y	Equipo 2 ~ Z	Referencia
MAPE	1.72%	3.24%	< 5%: excelente
MAE	10.17	36.20	Error absoluto promedio diario
RMSE	163.92	1,978.45	Errores ocasionales, sin deriva sistemática
R^2 test	0.9866	0.9220	> 0.90: muy bueno

Conclusión Ambos modelos superan el umbral del 5% de MAPE en el conjunto de prueba, lo que los hace aptos para presupuestación financiera con márgenes de error manejables.

5. Proyección de Costos y Horizonte de Predicción

Metodología de proyección

La proyección se realiza en dos etapas encadenadas:

- Etapa 1: Las materias primas relevantes (Price_Y para Equipo 1, Price_Z para Equipo 2) se proyectan 12 meses hacia adelante usando Holt-Winters con tendencia aditiva y estacionalidad de 12 períodos.
- Etapa 2: Los valores proyectados de la materia prima alimentan el ECM estimado para obtener la proyección del costo del equipo. La incertidumbre se propaga mediante 1.000 simulaciones bootstrap de los residuales.

Justificación del horizonte

Se seleccionaron 12 meses como horizonte de predicción por tres razones:

- La ventana del proyecto cubre aproximadamente este período según el enunciado del caso.
- Con 13 años de datos históricos mensuales (160 observaciones), proyectar más de 12 meses degradaría la confiabilidad de Holt-Winters significativamente.
- El intervalo de confianza del 95% se ensancha de forma manejable, ya que tenemos ~32 unidades en mes 1 a ~33 unidades en mes 12 para Equipo 1; de ~72 a ~111 unidades para Equipo 2.

Tabla de proyección — Equipo 1 (driver: Price_Y)

Mes	Pronóstico	Optimista (p10)	Pesimista (p90)	IC 95% inferior	IC 95% superior
Sep 2023	458.7	448.3	469.0	443.6	476.1
Oct 2023	447.7	436.5	458.2	430.9	463.8
Nov 2023	439.7	428.5	450.7	423.1	456.6
Dic 2023	450.2	439.6	460.9	433.3	467.2
Ene 2024	459.4	448.3	470.4	443.0	476.6
Feb 2024	467.6	457.2	477.6	450.6	484.3
Mar 2024	479.8	468.5	491.3	461.6	497.1
Abr 2024	486.1	475.1	497.2	470.9	502.6
May 2024	478.7	467.0	489.9	460.5	495.7
Jun 2024	462.2	451.1	473.7	445.7	479.8
Jul 2024	457.2	446.0	468.2	439.2	474.2
Ago 2024	461.8	450.4	471.3	444.2	476.9

Tabla de proyección — Equipo 2 (driver: Price_Z)

Mes	Pronóstico	Optimista (p10)	Pesimista (p90)	IC 95% inferior	IC 95% superior
Sep 2023	934.1	909.8	957.2	899.1	971.2
Oct 2023	941.2	909.1	969.4	895.3	991.7
Nov 2023	936.4	904.5	970.5	884.1	988.8
Dic 2023	941.5	908.8	975.2	889.3	997.2
Ene 2024	956.5	920.3	992.2	905.4	1011.9
Feb 2024	964.3	929.9	1000.5	912.5	1016.7
Mar 2024	969.6	935.9	1005.1	919.2	1018.6
Abr 2024	974.1	939.6	1009.5	918.4	1030.6
May 2024	952.8	917.4	989.7	902.2	1010.3
Jun 2024	935.8	899.8	973.2	879.0	988.2
Jul 2024	930.9	894.8	966.8	873.5	987.1
Ago 2024	936.4	901.0	972.8	882.1	992.8

Nota Para una planeación conservadora se recomienda usar el escenario pesimista (p90). Para compromisos contractuales, el escenario base. El IC 95% representa el rango de máxima cobertura del modelo.

6. Futuros Ajustes y Mejoras

Mejoras al modelo estadístico

- Modelo VECM multivariado: explorar un Vector Error Correction Model que modele simultáneamente ambos equipos y sus materias primas, capturando interdependencias cruzadas.
- Test de Chow o modelos con cambio de régimen: verificar si hubo quiebres estructurales en las relaciones (e.g., durante la pandemia 2020-2021) y ajustar los parámetros por sub-período.
- Incorporar variables exógenas: tipo de cambio, índices de producción industrial, precios del petróleo — que pueden ampliar el poder explicativo del modelo.

Mejoras a la proyección

- Proyección probabilística con MCMC: reemplazar el bootstrap paramétrico por simulación Monte Carlo con Cadenas de Markov para una propagación de incertidumbre más rigurosa.
- Modelos de proyección alternativos para materias primas: evaluar ARIMA automático (auto_arima) o modelos Prophet de Meta para comparar contra Holt-Winters.
- Actualización continua: implementar un pipeline de re-entrenamiento mensual a medida que llegan nuevos datos de precios.

Mejoras al agente de IA

- Memoria persistente: agregar una base de datos vectorial (e.g., ChromaDB) para que el agente recuerde conversaciones anteriores entre sesiones.
- Interfaz web: migrar de consola a una interfaz Streamlit o FastAPI + React para uso por parte de la gerencia sin conocimientos técnicos.
- Alertas automáticas: configurar el agente para que notifique por correo o Slack cuando el precio proyectado supere un umbral presupuestal definido (detección de anomalías).
- Integración con datos en tiempo real: conectar a APIs de Bloomberg, Reuters Eikon o datos públicos de commodities para actualizar las proyecciones automáticamente.

Arquitectura y escalabilidad

- Despliegue en la nube (AWS/Azure/GCP): migrar el pipeline a una arquitectura serverless con orquestación de workflows (AWS Step Functions o Azure Data Factory).
- MLOps: implementar seguimiento de experimentos con MLflow o Weights & Biases, versionado de modelos y monitoreo de drift en producción.
- API REST: exponer el modelo como servicio REST para integrarlo con los sistemas ERP de la empresa (SAP, Oracle).